

# 杨贺淞

☎ 15141997955    ✉ hesong.yang@foxmail.com

📞 15141997955

🏠 在职    📍 上海    📄 高性能计算系统开发

## 工作经历

### 小红书

2024年01月 - 至今

引擎架构部

上海

- **GPU算子库建设：**
  - **余弦相似度Fusion Kernel开发：**在Ampere/Ada架构上，使用PingPong、Tiling、多级流水、共享内存、合并访问、异步传输及Tensor Core **mma**指令，实现N>>M的融合Kernel开发，相比torch.cosine\_similarity**吞吐提升30%+**。
  - 完成对常用PTX指令的函数化封装
- **GPU推理优化：**对模型采用动态Shape、FP16/FP8、Kernel Fusion提升模型吞吐80%+。
- **国产芯片模型部署：910B(280T)和燧原C100卡型**在小红书首个服务上线。
- **稀疏推理引擎优化：**使用SIMD指令、Kernel融合、图优化及混布等优化方式实现CPU推理效率**翻倍**，节约资源**130,000+core**。
- **召回架构升级：**使用AMD 9004 AVX512指令集，25W Item双塔模型计算P99 5ms以下，整体吞吐提升**5倍**。

### 阿里巴巴/之江实验室

2021年07月 - 2024年01月

燧原之江联合中心

杭州

- **燧原芯片大模型推理优化：**

XLA在JIT模式下，接入XLA的DynamicUpdateSlice操作，提升XLA对动态图的支持能力，解决重复编图产生的性能问题。通过对token进行padding与定长设置，降低JIT图模式对推理的影响。
- **燧原芯片软件栈内存优化：**

AI软件栈实现Zero-3、ZeRO-Offload、L2L等策略，支持大模型在国产芯片上的分布式训练与推理。
- **AI模型部署系统开发：**

模型部署CPU核心绑定开发：通过支持线程与CPU核心绑定，减少任务的频繁切换与抢占。  
Socket、NUMA对齐特性开发：部署分配资源时将资源分配到相同Socket，避免跨Socket的性能开销。

## 专业技能

- 熟悉C++、CUDA、PTX开发及Nvidia Ampere/Ada架构，具有GPU **Kernel开发优化**经验
- 熟练使用Nsight Compute/System 性能分析工具
- 熟悉Tensorflow/XLA、TensorRT、NVIDIA Triton框架

## 发表论文

- ZeRO-Offload: forward-gradient scheme for efficient full parameter fine-tuning of billion-scale language models ( 通讯作者 )
- Face repairing based on transfer learning method with fewer training samples: application to a Terracotta Warrior with facial cracks and a Buddha with a broken nose ( 通讯作者 )

## 教育经历

西安交通大学-机械电子-硕士

2018年09月 - 2021年06月

西南交通大学-自动化-本科

2014年09月 - 2018年06月